面向聚变堆屏蔽快速方案迭代的块结构体素—GPU-MOC协同设计

第 1 节 研究背景：聚变堆屏蔽设计为何需要快速反馈

1.1 设计迭代对快速反馈的需求

Moreno、Bader 和 Wilson（2024）利用 ParaStell，以 WISTELL-D 为例，在等离子体边界与磁体线圈之间的可用空间约束下，改变包层与屏蔽层的三维厚度分布，并计算氚增殖率与磁体核热，比较不同配置；其参数化建模将几何生成纳入这一迭代流程。[1] 作为历史先例，Liew 与 Ku（1991）通过迭代输运计算调整 CIT 试验大厅的混凝土组成与屏蔽厚度，筛选满足屏蔽和结构要求的方案。[2] 因此，在给定设计周期内完成更多方案比较，需要缩短每轮从参数修改到性能反馈的时间。

1.2 复杂几何带来的建模与评估成本

复杂几何的成本也发生在输运求解之前。H. Tsige-Tamirat、U. Fischer、A. Serikov 和 S. Stickel（2007）的 McCad 研究指出，复杂蒙卡几何建模耗时；其 ITER 40°扇区模型包含 916 个实体，除 CAD 转换外，还需检验转换后模型的一致性。[3] 这一实例说明，几何处理和模型检查属于获得可信评估结果的实际工作量，速度评价不能只覆盖输运扫描。

1.3 速度目标与约束条件

本课题将“快”定义为从方案修改到获得可用屏蔽响应结果的完整耗时，纳入几何与材料更新、模型检查、必要的表示—执行选择与预运行、数据准备及传输、全部输运迭代和响应提取。比较须同时满足预设的目标响应误差容限与峰值显存预算；迭代残差收敛不能替代响应精度达标。目标响应及其误差判据在比较前固定，精度用于界定可接受的计算配置，超过要求的精度不自动构成收益。

首次计算计入初始化与轨迹准备的全部成本；更新后计算则依据实际可复用的数据，计入必要的重建、缓存失效处理和重新求解成本，两者分别报告。未知量减少、单次扫描变快或迭代次数下降均不足以单独判定收益，判据是达标所需的完整方案迭代时间是否缩短。对连续更新序列，还需同时报告逐轮与累计耗时，避免将一次性准备成本的摊销误认为每轮更新均可实现的加速。

1.4 研究缺口与本课题定位

Zhou 等（2025，预印本）研究了轨迹显式缓存、在线生成与负载均衡；Kim 等（2026，已在线发表，online first）已探索非结构网格上的 GPU-MOC。[4]、[5] 本课题的体素指确定论 MOC 的空间 / 材料离散单元，定义见 3.1；蒙卡几何体素化不进入本课题实验路线。就上述工作报告的实验范围而言，它们未将均匀细体素与局部加密体素作为与 GPU 执行策略联合比较的变量，也未计入方案修改引起的更新成本。因此，本课题在固定响应精度要求与显存预算下，联合比较体素表示与轨迹生成 / 缓存、轨迹分组和通量归约策略，检验局部加密能否在关键输运路径上满足精度要求的同时缩短方案迭代周期。收益归因须同时考察准备时间、单次扫描时间与迭代次数；新增准备开销、粗细分界面处理开销和块间负载不均可能抵消求解时间的节省，本课题不预设局部加密在所有条件下更快，而是检验其在何种条件下更快、在何处失效。

第 2 节 研究问题与目标

2.1 RQ1：局部加密是否缩短达标方案周期?

在固定响应精度要求与显存预算下，局部加密能否比均匀细体素缩短方案迭代周期? 未知量减少可能伴随准备开销、扫描耗时或迭代次数增加，净收益并不显然。对同一几何修改序列，固定物理输入、角能离散、收敛准则和 GPU，给予两种表示相同执行策略候选集与调参预算，比较各自最快达标配置按 1.3 定义的完整耗时，并记录响应误差和峰值显存。最快达标配置在调参场景上确定并冻结，正式比较在独立的测试场景上进行，详见 6.1。

2.2 RQ2：哪些环节及其相互作用主导净收益?

若 RQ1 出现加速或减速，哪些环节及其相互作用主导净收益? 表示变化可能同时改变轨迹分段数、粗细分界面处理和归约冲突，仅比较总耗时难以归因。在 RQ1 条件下，按 6.3 第一层固定两种表示各自的网格配置，交叉切换缓存 / 在线生成、轨迹分组开关及直接原子累加 / GPU 线程块内归约后累加，进行单因素与交互对照；测量准备、逐轮扫描及其分界面处理和归约子项耗时，结合迭代次数与负载分布判定主导环节。

2.3 RQ3：净收益在什么条件下失效?

RQ2 识别的开销在什么条件下使局部加密不再更快? 加密比例相同，分界面分布或修改范围不同，仍可能改变收益。固定物理与求解设置，按 6.3 第二层预先登记的配置分别改变加密比例、粗细分界面密度、修改范围和显存预算，重复两种表示的配对

比较；以完整耗时之差及重复测量波动定位等时边界，单列精度或显存不达标区，并用未参与拟合的算例复核。

2.4 研究目标与验收口径

1. **交付局部加密 GPU-MOC 原型**；以网格覆盖、轨迹连续性、粒子守恒及解析或确定论参考算例误差通过预设检查为达成。

2. **交付均匀细体素基线与可复现实验集**；以约束、调参预算一致且计时结果可复现为达成。

3. **形成收益归因模型**；以分项计时能重构总耗时、主导因素及交互效应经消融复核为达成。

4. **给出失效边界与表示—执行选择准则**；以未参与建模的算例检验模型预测的收益方向与失效位置是否与实测一致，并核对实测覆盖范围内的两条选择准则及一条不确定带处理规则，统计方向不一致比例、各类覆盖率与可定位边界的偏差为达成。

第 3 节 方法定位：规则块体素为何适合这一快速求解路径

3.1 确定论空间离散与蒙卡几何体素化的区分

本课题的体素是确定论 MOC 的空间 / 材料离散单元，承载材料标识及源项、通量等离散量，并确定特征线分段与积分所用的区域。蒙卡几何体素化用于以体素描述几何及材料区域，与上述确定论离散的用途不同，不进入本课题实验路线。复杂曲面与通道映射为网格上的材料分布后，有望通过统一的单元接口访问；其表示是否可接受，仍由既定响应精度约束判定。

3.2 规则块内的索引、遍历与数据布局

规则块内采用等间距笛卡尔单元，可由块原点、网格步长和整数索引确定块内位置及邻接关系；在块内连续遍历时，有望减少几何查找与间接寻址。Amanatides–Woo（1987）给出了递推穿越相邻体素的算法，构成规则网格射线遍历的高效先例。[6] 这一依据限于规则网格遍历，不提供 GPU 加速结论；块间定位与跨层衔接仍需另行处理。

在数据组织上，AMReX 以逻辑矩形块和连续多维数组存储网格量，并允许针对算法选择不同布局。[7] 借鉴这一组织原则，规则块有望为材料、源项与通量提供可预测的地址映射；只有访问顺序与数组布局相匹配时，才可能降低 GPU 访存开销，具体机制留待第 4 节讨论。当细化以整块为单位、而需要较细分辨率的区域仅占块内一部分时，可能连带增加其余区域的单元数，形成块级粒度浪费。

3.3 已有块结构框架与待实现的局部加密能力

本课题的工程起点是：**块结构网格框架已有；MOC 求解器本体与 GPU 资源状态见 9.1；局部加密尚未实现，需本课题完成实现与正确性验证。** 待补齐的能力包括多分辨率块组织、粗细邻接定位和跨层轨迹衔接，并须检查参与输运计算的有效网格单元覆盖完整、无重复计入，以及轨迹分段有无遗漏或重复；层级覆盖方式按代码核实，不推定采用树结构。粗细分界面处的索引转换和衔接处理可能增加准备与扫描开销，不能由块内规则性推断其成本。只有这些能力通过验证后，局部加密配置才能进入与均匀细体素的速度比较。

3.4 全域细化的准备时间、扫描时间与显存压力

全域细化会扩大网格规模：在固定长方体计算域中，三个方向的步长均减半，单元数增为八倍；若每单元存储量不变，相应网格场数组也增为八倍。若仍需逐单元材料赋值与初始化，其准备工作量亦增加。因此，材料映射、数组建立与必要数据传输的耗时，以及计算全过程的峰值显存，都需要随网格规模重新计量；单元数的增长倍数不能直接替代总耗时的增长倍数。

输运阶段，网格边界增多可能增加特征线分段及逐段积分工作；Gaston 等（2021）指出，三维 MOC 的线段规模可能超出可用存储资源。[8] 实际扫描耗时仍取决于分段数量与访问方式，迭代次数亦不能由单元数推出。全域细化的代价须分别落实为准备时间、累计扫描时间与峰值显存，再按 1.3 计入完整方案周期；均匀细体素在达标条件下的完整耗时，将作为第 5 节比较的参照。

第 4 节 加速机制：GPU-MOC 的速度从哪里来

4.1 轨迹并行扫描与数据访问

固定本轮源项和入射边界值后，不同特征线可并行扫描，线内仍须沿程递推；轨迹之间仍可能通过源更新与边界传递发生迭代耦合。[9] 连续访存有望减少内存事务，线程束内分支发散则可能使不同路径分开执行。[10] 扫描时间、内存事务量与活跃线程比例共同表征其效果。但其对完整周期的影响取决于准备、缓存、归约和迭代成本。

4.2 轨迹在线生成与显式缓存

在线生成（OTF）在扫描时生成线段，节省轨迹存储但重复几何计算；显式缓存（EXP）以预生成和存储成本换取后续复用。Zhou 等（2025，预印本）报告 EXP 相对 OTF 的加速比为 1.5–10；其结果提示，减少在线生成分支与非连续访存可能缩短扫描时间，但未拆分两者贡献，其实现也允许部分缓存。[4] 轨迹复用有望摊薄准备成本；

几何修改导致缓存失效或读取受带宽限制时，两者快慢关系可能改变。须计量准备 / 扫描时间、峰值显存及缓存重建耗时。但其对完整周期的影响取决于准备、缓存、归约和迭代成本。

4.3 轨迹分组与负载均衡

轨迹分段数悬殊时，短轨迹线程先结束，线程束内部分通道空闲；按工作量分组有望缩短等待，但排序也耗时。Zhou 等按分段数重排后，相对未均衡版本报告约 10% 的提升。[4，图 8] 分组还可能改变访问局部性，工作量更均匀不保证扫描时间同比下降。效果须落实为扫描时间、排序时间和负载不均度，如线程束内分段数最大值与均值之比。但其对完整周期的影响取决于准备、缓存、归约和迭代成本。

4.4 通量累积冲突与归约策略

多条轨迹向同一单元同一能群累积通量时，原子操作可避免更新丢失，但高竞争可能导致串行化。低竞争时直接原子累加可能较省时；同址贡献集中时，GPU 线程块内归约后累加有望减少全局原子请求，却增加索引匹配、同步与临时存储。[11] 若贡献分散在多个线程块中，块内合并范围有限，跨块累加仍可能产生竞争。需记录归约耗时、临时存储量，并以同批次同址更新次数作为冲突代理量。但其对完整周期的影响取决于准备、缓存、归约和迭代成本。

4.5 已有加速报告的计时口径与适用条件

该预印本以 CPU OpenMOC-OTF 为基线，采用 C5G7 三维扩展的临界本征值问题（轴向挤出、平源近似），15 档轨迹数约 0.9 万至 1640 万条。表 1 列出 12700KF 搭配 1080Ti / 2080Ti / 3060 / 4090，以及 32 核 AMD 搭配 MI60；图 6 未明确对应硬件、CPU 线程数及计时是否覆盖准备、缓存建立、归约和完整迭代。**摘要 300–400 倍与正文图 6 及 5.2 节约 30–100 倍口径不一致**，文中未解释差别。[4，表 1、图 6 及第 5 节] 本课题引用 EXP/OTF 和负载均衡的机制依据，不据这些倍数设定速度预期，也不将其换算为完整方案周期缩短。

第 5 节 局部加密：如何服务快速方案迭代

5.1 定位：精度是约束，速度是判据

局部加密在本课题中的作用，是在满足固定目标响应精度与显存预算的条件下，避免将全域细化成本施加于非关键区域；精度是约束，速度是判据，不以同等网格下提高精度为目标。Baker 等（2013）采用目标响应驱动的各向异性网格自适应，提供响

应导向的细化先例，但不支持块结构 GPU-MOC 上的加速结论。[12] 在本次核验的文献范围内，该组合尚缺少公开的直接证据，本课题的收益判断属于待检验命题。

5.2 可能节省的成本及成立条件

准备时间可能节省，其实现取决于非关键区域采用粗网格仍满足响应约束，且省去的细网格构建工作超过区域判定与块管理开销。扫描时间可能节省，其实现取决于粗区实际轨迹分段减少，且跨界处理和访存代价未抵消节省。累计迭代耗时可能下降，其实现取决于每轮耗时与迭代次数共同决定的实测总量。收敛不恶化是有利条件，而非准入条件；累计迭代耗时是否下降最终以实测为准，即使迭代次数增加，累计耗时仍可能下降。未知量减少不意味着迭代次数减少，必须同时记录每轮耗时与达标所需迭代次数。

5.3 块级粒度浪费

整块细化会使块内非关键区域一并细化。粒度浪费取决于关键区域占比、空间分布与块尺寸，表现为额外细单元、轨迹分段及显存占用。占比较低不必然对应同等比例的时间浪费，因为不同区域的轨迹工作量不同；块尺寸变化还会改变块数和界面数量，不能仅凭细单元数判断其速度代价。

5.4 粗细分界面处理成本

粗细分界面涉及层级索引转换、跨界轨迹分段及网格更新后的相关数据重建。AMReX 的实现涉及跨层数据交换与元数据维护，为层级管理成本提供先例，但不能替代 MOC 的计时证据。[7] 这些操作在 GPU 上可能引入分支；若采用跨块交换或同步重建，还可能产生同步等待。相关耗时需归入实际发生的准备或扫描环节，分项测量，不能一概视为一次性成本。

5.5 块间负载不均

在按空间块分配任务的实现中，粗细块的轨迹穿越数、分段数与界面处理量可能不同，按块数均分可能导致轻任务先结束而部分线程空闲。沿用第 4 节线程束内分段数最大值与均值之比的口径，并另行定义块级不均衡度（块间分段数标准差与均值之比），两者分别记录；结合活跃线程比例和扫描时间判断其影响；网格层级本身不能替代工作量测量。

5.6 收益判据：完整达标方案周期是否缩短

收益判据是按 1.3 定义的完整达标方案周期是否缩短，首次计算与方案更新后的计算分别计时；未知量或单次扫描时间下降不能代替这一判据。当关键区域较集中、块

级额外细化受控且收敛稳定时，局部加密可能更快，其实现取决于省去全域细化所节省的时间超过数据重建、界面处理和负载不均的新增耗时。若更新频繁触发重建，或收敛恶化抵消扫描节省，其收益就可能失效。

第 6 节 研究设计与方法：表示—执行联合比较

6.1 比较对象与公平性约束

比较均匀细体素与块结构局部加密，固定物理输入、角能离散、轨迹采样、浮点精度、收敛准则与迭代加速器、GPU 硬件、响应定义、误差容限及显存预算。均匀侧允许调网格尺度，局部侧允许调块尺寸、层级与加密阈值；执行参数采用相同候选范围。双方使用同一搜索规则、等额 GPU 时预算和候选数上限，任一达限即停，记录实际消耗。择优标准为：在预先指定的场景或更新序列上，按 1.3 定义的完整达标周期取最短者；表示参数与执行参数联合择优，不分开择优后再拼接。择优所用场景与正式比较场景分离，正式比较前冻结所选配置；更新时若需重调，其耗时计入方案周期。上述固定条件针对每个配对比较点；第二层不同点之间允许按预先登记方案受控改变几何布局、更新序列与显存预算，同一点内两种表示的物理输入、更新序列及预算保持一致。

6.2 精度达标条件与显存约束

参考值由解析解或独立细化收敛的确定论解提供，不能直接采用被比较的均匀网格结果。数值参考解须经过空间、角度与轨迹细化检查，逐级变化量小于响应容限的五分之一；这仅是稳定性检查，临界样本须先加严复核。本课题将前述“目标响应误差容限”具体化为绝对 + 相对组合容限，以避免参考响应接近零时单纯相对误差判据不稳定。正式比较前冻结响应集合、参考值及两项容限，各响应按 $|R-R_{ref}| \le \varepsilon_{\mathrm{abs}}+\varepsilon_{rel}|R_{ref}|$ 验收。全部响应达标、求解收敛且峰值显存不超过预算，才进入时间比较；参考不确定度影响判定的样本暂不比较，标准不得事后放宽。显存包含缓存、临时缓冲及重建中新旧数据并存的峰值，以分配日志和驻留监测核验。单方不达标时保留原因，不计算配对速度差；参考解生成成本单列。

6.3 消融因素及控制方式

按 6.1 的择优标准，第一层表示因素的两个水平为对等调参预算内择优并冻结的一对均匀细体素配置与局部加密配置；在该对配置内不再重调网格。采用表示二水平×轨迹三水平×分组二水平×归约二水平的因素组织。均匀 / 局部加密用于检验建网、扫描及迭代耗时对空间离散的敏感性；在线 / 全缓存 / 部分缓存覆盖生成时间与存储量的权衡，部分缓存容量和选取规则在正式测量前冻结，关注准备与扫描耗时。分组关闭

／开启分别保持原序和按分段数分组，用于区分排序成本与线程等待，关注准备及扫描耗时。直接原子／线程块内归约后原子累加用于区分冲突与局部聚合代价，关注归约时间及临时显存。每组消融内部固定两种表示各自的网格配置及其余非目标参数；显存不可行组合保留为约束记录。

部分缓存容量属于本课题的设计选择，并非引用 Zhou 等（2025）的实现参数；容量上限初设为显存预算的四分之一，以限制轨迹缓存占用，为通量、材料数据和临时缓冲保留预算。该比例经预实验校准后对两种表示统一冻结；缓存对象按固定轨迹编号顺序选取，不随分组开关改变。若全部轨迹均可装入该容量，则标记为全缓存，不重复作为独立的部分缓存样本。

消融实验分两层。第一层（RQ2）除表示二水平（即 6.1 择优冻结的那对配置）外，仅交叉执行策略因素，用于归因。

第二层（RQ3）使用预先登记的多组配置，选取原则为分层抽样而非择优。关键区域占比通过几何族内不同屏蔽布局变化实现；修改范围与更新频率通过 6.5 的三类场景序列实现，重建比例由序列中需要重建的更新所占比例控制；显存预算通过受控的预算档位实现。配置按块尺寸、加密比例和界面密度分层抽样，依据预实验提示覆盖候选边界附近及两侧，不预设一定观测到收益方向转换。每组内部执行同一套预先登记的执行策略消融规则子集，用于刻画边界关系。配置点数量须与 7.3 的模型复杂度匹配；两层配置集、采样规则及点数均在正式测量前登记冻结，不得用留出数据追加配置或重新择优。

6.4 测量指标与分项计时

沿用 1.3 的计时起止点，准备阶段截止首轮正式扫描前；逐轮扫描包含在线生成、输运、界面处理和通量归约，源更新、收敛检查及结果输出另记。缓存建立只计准备，不重复计入扫描；重建是更新准备的子项。记录迭代次数、峰值显存，以及线程束内分段数最大值／均值、块间分段数标准差／均值。鉴于 CUDA 异步执行，完整周期用主机单调时钟计量，终点等待 GPU 完成；GPU 阶段以事件计时，不逐内核强制同步。计时依据为 NVIDIA《CUDA C++ Best Practices Guide》（Release 13.4）第 9.1 节“Timing”，主机计时与异步同步要求参照[10，§9.1.1]，GPU 事件计时参照[10，§9.1.2]。融合内核无法独立拆时的子项标为插桩估计，另跑并校准测量扰动；嵌套子项不再次相加，CPU／GPU 并发及跨流重叠按统一时间轴去重。

另设“表示—执行选择与预运行”独立计时项，包括为当前方案服务的配置择优、特征提取、收敛预估计等计算，计入完整周期，与正式扫描划界，不重复计入准备或扫描。费用按实际发生次数记录；离线调参成本另报，评价含该投入的累计周期时只计一次，不向每次更新重复挂账。

6.5 方案更新场景

首次计算从无方案缓存状态开始，计入初始化、建网与建缓存，选择与预运行由初始化环节触发；可复用更新限定为网格和轨迹保持有效的源项修改，仍计输入处理、有效性检查与数据刷新，选择与预运行由有效性检查环节触发；重建更新采用几何或网格变更，计入失效判定、受影响数据重建和传输，选择与预运行由失效判定环节触发。上述场景归属仅标明费用来源，耗时统一进入 6.4 的独立计时项，并从相应父项中扣除，不再重复相加。两种表示采用相同方案更新序列与初值规则，每次重复恢复对应场景初态。分别报告每轮扫描、每次方案耗时，以及包含首次计算的累计耗时，不用更新耗时替代首次成本。第二层各序列预先登记修改范围、固定设计评估时段内的更新次数及重建更新比例；序列构成在正式测量前冻结。

6.6 收益归因方法

在同一算例与更新场景内，固定其他因素计算单因素配对时间差，再以该差在两种表示间的差值刻画交互作用。统计顺序为：先在每次配对重复内构造单因素差与交互差，再对差值序列汇总中位数并重采样；不得先汇总各因素中位数再相减。报告配对差中位数、四分位距及配对自助重采样的 95%置信区间；重采样采用预设次数（如 2000 次），在预实验中检查区间端点对重采样次数的敏感性，并在正式比较前冻结；区间跨零或差异未超过实测计时扰动上界时，不判定收益方向。依据去重后的表示—执行选择与预运行、准备、逐轮扫描、其他迭代工作、输出及显式记录的等待重构总时间，与独立端到端计时核对：相对偏差超过预设阈值时，暂停归因并排查遗漏、重叠及插桩扰动。阈值初设为 1%，在预实验中依据实测计时噪声与插桩扰动校准，并在正式比较前冻结；不得根据正式比较结果事后放宽，也不得以未分类残差补齐。单元数仅作描述，归因须有相应分项时间变化支持。第一层的交互归因结论限于该对择优配置及第二层实测支持的邻域，不外推为表示—执行的普遍交互规律；可迁移性按 7.5 的框架可复用界定。

6.7 可复现性

每配置、每场景拟以 10 次独立重复为起点，预实验后依据配对差的实测波动及置信区间宽度要求确定正式测量次数，必要时增加，并在正式比较前冻结；每组配对两侧采用相同重复次数，运行顺序随机化。自助重采样用于估计统计不确定性，不能替代独立重复。固定可控频率与功率上限，温度稳定后运行，清除后台 GPU 负载；不能锁频时记录频率变化，超出预设温度或负载范围的运行标记并重测。预热不保留方案状态，首次场景重启进程并计初始化。运行随机化及自助抽样种子固定。以 JSON 保存输入、配置、代码提交和软硬件版本，以 CSV 逐次保存响应、误差、显存峰值、迭代次数、时间子项及失败标记；原始时间轴随记录归档。

第 7 节 失效边界与可迁移的协同设计准则

7.1 局部加密无时间收益与显存不可行

场景配对差是在同一场景、同一重复内，局部加密与均匀细体素按 1.3 定义的完整周期之差，即 $d_{s,j}=T_{\text{局部},s,j}-T_{\text{均匀},s,j}$，场景统计量为 $\Delta T_s=median_j\left(d_{s,j}\right)$。序列累计配对差是在固定更新序列上，两种表示各自累计完整周期之差；先在每次重复内汇总首次计算及全部更新周期，再作两种表示之差，最后对差值序列取中位数，记为 ΔT_{seq}，不得将各场景中位数直接相加。以下统称 ΔT 时，图表须注明使用场景统计量还是序列统计量。

两种表示均满足精度与显存约束时，ΔT≥0 定义为局部加密无时间收益，即均匀细体素不慢于局部加密；是否能够明确判向，仍按 6.6 与 7.3 的区间及噪声判据判断。ΔT=0 为等时边界，是以连续时间差刻画的收益边界。另以峰值显存超过预算定义显存不可行，该配置直接退出比较，形成可行域的约束截断，不记为时间收益失效。精度未达标的样本也不进入时间边界估计。

7.2 边界的描述量与方向假设

边界数据来自 6.3 第二层预先登记的多组配置。本课题类比 AMReX 的块管理经验选取描述量；该文献提供块划分、网格重建和负载管理的实现参照，不直接支持以下 GPU-MOC 边界方向假设。[7，§5.2] 其他条件相近时，关键区域占比下降、块尺寸增大若扩大非关键区细化范围，预期推向无时间收益侧；缩小块尺寸则可能增加界面密度。界面密度以单位轨迹长度的粗细界面穿越次数表示，其上升、块间分段数标准差 / 均值增大，以及局部 / 均匀迭代次数比升高，预期均推向无时间收益侧。重建比例升高且局部侧重建增量为正时，预期同向。在单位更新的时间差及更新构成保持不变时，提高更新频率会增加固定评估时段内的更新次数，预期放大更新阶段累计时间差的绝对值。单次更新上的 $|\Delta T_s|$ 不会因此自动增大；完整累计周期的收益方向还须计入首次准备成本。收敛变化按 5.2 作为成本解释量，不作为准入条件；上述预期须由 7.4 检验。

7.3 适用区间、无时间收益区间与不确定带

基于 6.3 第二层数据建立 ΔT 模型，先拟合主效应；仅当交互项在预实验中可分辨、独立配置点数满足参数估计与剩余自由度要求且设计可辨识时，才纳入相应交互项。第二层配置点数量与候选模型复杂度在正式测量前匹配并登记，重复运行不计作新增独立配置点。配置点数不足时采用可加主效应模型，并在 7.4 留出检验中报告该简化对边界估计的影响。实测统计区间来自 6.6 的配对差置信区间，用于已实测配置点上

的方向判定：通过噪声判据后，区间完全位于零以下者列为适用区间，完全位于零以上者列为无时间收益区间；区间跨零或差异未超过计时噪声者列为不确定带。

模型预测区间包含模型误差项，用于估计待测区域的边界位置及指导后续测量选点，不直接触发表示—执行组合选择。本课题采用保守方案：两条选择准则只在完成独立检验的实测覆盖范围内生效，不将预测符号直接外推为选择结论。预测区间在 7.4 留出检验中检查覆盖；后续选点限于新一轮预先登记的测量，不得据原留出结果回改本轮冻结配置。若校准模型或修订区间，须保留原检验结果，并用新的独立留出算例复检。

拟合零水平集估计等时边界，即在精度与显存均达标的参数空间内，以 $\Delta T=0$ 为分界区分适用区与无时间收益区，分界附近保留不确定带；允许多个不相连区间，不跨越离散配置跳变强行插值。沿预定参数路径，边界偏差定义为预测零点到留出实测过零区间的距离，按参数范围归一化，同时报告区间宽度。实测判向不确定性、模型预测不确定性及留出偏差分别记录；没有实测支持的区域保留为待测范围，不给出组合选择结论。

7.4 留出算例检验与准则否证

留出算例按几何族划分，不参与 6.1 调参与 7.2 描述量的建模。模型预测仅使用事前可得信息；收敛等事后量若用于预测，须由预运行估计，其耗时归入 6.4 独立计时项，并按 6.5 记录触发场景。模型方向与实测方向的比较仅用于独立检验，不绕过 7.5 的实测覆盖限制。

两种表示均通过精度、收敛与显存约束的样本记为可行样本；实测区间通过 6.6 噪声判据、且预测方向与实测方向可明确核对的可行样本记为可判向样本；预测方向仅在含模型误差的预测区间不跨零时判定，不对预测区间套用实测计时噪声判据。分报总体覆盖率（可判向样本 / 全部留出样本）、可行性覆盖率（可行样本 / 全部留出样本）、可行域内判向覆盖率（可判向样本 / 可行样本），并在可判向样本中统计方向预测不一致比例。可行样本数为零时，判向覆盖率记为不适用，不据此判定时间选择准则失效。

准则是否成立依据可行域内判向覆盖率与方向不一致比例，采用正式检验前冻结的验收要求，不以总体覆盖率作为判据；能够定位过零区间的样本还须满足预设边界偏差要求。不满足相应要求时，按原因报告准则在该测试范围内不成立及适用范围收缩。未进入判向的样本分类记录显存不可行、精度未达标、参考不确定度不足以判定、区间跨零及计时噪声不可分辨等原因。没有实测过零区间时，不宣称定位准确。

7.5 条件化准则与迁移范围

拟形成两条待检验的选择准则。在精度与显存达标、实测区间完全位于 $\Delta T<0$ 且通过 6.6 噪声判据时，选择局部加密及对应的轨迹、分组、归约组合；其适用条件为留出检验通过，且输入与更新场景处于实测覆盖的验证范围。在相同约束下，实测区间完全位于 $\Delta T>0$ 且通过噪声判据时，选择均匀细体素及对应执行组合；其适用条件为该组合通过独立检验，且输入与更新场景处于实测覆盖的验证范围。

另设一条不确定带处理规则：实测区间跨零或差异未超过计时噪声时，不给出组合选择建议，标记为需补充测量；重复波动主导时增加独立重复次数，边界定位过粗时加密邻近参数采样，留出偏差主导时新增独立留出算例，并保留原有检验结果。未实测区域仅用预测区间指导选点，完成实测及检验前不作组合选择；补测后仍无法判向，则维持未判定状态。其适用条件为精度与显存约束已满足，但时间收益方向尚不能可靠分辨或尚缺实测支持。

已有块结构网格框架为几何与网格规模变化提供构造基础，二者及基准 GPU 容量内的显存预算变化拟列入验证范围，具体设备使用条件仍须确认。能群数迁移需要匹配的多群截面库，跨 GPU 架构迁移需要额外设备；这些资源尚未确认，暂列讨论边界。

本课题所称“可迁移”，指条件化判定框架可复用：在新条件下，仍可沿用先检查约束、再判断时间收益方向、最后处理不确定性的流程，回答“在何种条件下选择哪种表示—执行组合”。具体参数区间须重新标定并经独立检验，已有数值范围不直接外推。

第 8 节 与最接近工作的差异

8.1 与 Zhou 等（2025）的差异

- **已有工作**：Zhou 等（2025，预印本）实现三维 MOC 的 GPU 并行，比较在线生成与显式轨迹缓存，并检验基于轨迹分段数的负载均衡。[4]
- **不重复内容**：本课题不将 GPU 移植、EXP / OTF 比较和 Zhou 等报告的加速机制作为新增贡献。
- **拟新增内容**：面向聚变屏蔽方案迭代，将体素表示纳入联合变量，把准备与方案更新成本计入达标方案周期，回答能否缩短周期及哪些环节主导收益（RQ1、RQ2）。

8.2 与 Baker 等（2013）的差异

- **已有工作**：Baker 等（2013）在含探测器的固定源屏蔽计算中，采用目标响应驱动的各向异性网格自适应，提供响应导向的细化先例。[12]
- **不重复内容**：本课题不将目标响应驱动细化的思想作为新增贡献，也不以精度提升作为优化目标。
- **拟新增内容**：刻画局部加密无时间收益的条件（RQ3），区分时间收益不足与显存约束截断，形成经留出检验的局部 / 均匀表示及执行组合选择准则，并按 7.5 对不确定带内结果暂不作选择、转入补测。

8.3 预期贡献

方法上，拟形成以精度与显存为约束、以达标方案周期为判据的表示—执行联合比较与收益归因框架。工程上，拟提供支持块结构局部加密、完成正确性验证的 GPU-MOC 研究原型。数据上，拟提供覆盖两种表示、执行组合及首次与更新场景的可复现实验集，保留无时间收益、显存不可行和不确定带结果。

第 9 节 可行性与风险

9.1 已有基础与待落实资源

块结构网格框架已有，状态为**已确认**。

- **MOC 求解器本体：待确认**。须核实是否可访问、可修改及其 GPU 化程度。
- **求解器接口：待确认**。须核查网格、轨迹、截面与通量接口，以及代码访问条件。
- **GPU 设备：待确认**。型号、显存、使用权限和可用时段尚未提供。
- **性能分析工具：待确认**。安装情况、版本兼容性和性能计数器访问权限尚未核实。
- **申请人课程与计算基础：已确认（据本人提供材料）**。已修数学物理方法、辐射屏蔽设计、核反应堆物理等课程，具备 Python、C++及 Linux、Git 开发与版本管理经验。
- **申请人相关项目经历：已确认（据本人提供材料）**。具有 Geant4 屏蔽装置、加速器大厅及电子加速器靶结构建模经历，以及基于 OpenMC、Serpent 参考结果的群常数校准项目经历，涉及敏感性分析、降阶建模和优化；硕士课题围绕石墨吸收群常数自动化修正开展，当前在研，不将预期成果列为已完成。上述经历支撑输运建模、屏蔽评估与计算流程开发，不等同于已有 GPU-MOC 实现能力。
- **GPU 编程与 MOC 实现能力：尚不具备，需系统学习**。已有 Python、C++编程及粒子输运建模经验，可为学习 GPU 编程与 MOC 实现提供一定基础；专项能力须通过后续学习、代码实践与正确性验证建立，具体学习安排尚待确定。

9.2 第一风险：块结构局部加密尚未实现

局部加密需本课题在已有网格框架上从头实现并验证，是后续表示—执行联合比较的前提；缺少这一能力，RQ1—RQ3 均无法回答，因而构成第一风险。

- **结构检查**：核验参与输运计算的有效网格单元覆盖完整、无重复计入，检查层级关系与邻接索引一致；层级覆盖方式按代码核实，不推定采用树结构。
- **轨迹检查**：核对跨界轨迹的材料序列、分段总长度及几何正反向一致性，排查漏段和重段。
- **输运检查**：用解析算例及经收敛核验的确定论参考解，检查目标响应与粒子平衡。

第一年里程碑为通过上述三类检查，交付局部加密最小实现、验证用例和正确性报告；未通过时不进入两种表示性能优劣的判断。

9.3 其他风险及缓解措施

- **显存超预算**：缓存及重建暂存使峰值越界；切换部分缓存或在线生成，释放失效缓存并分批重建，仍超限则按 7.1 剔除配置。
- **准备成本过高**：区域判定、分组及重建抵消扫描节省；定位准备阶段热点，对依赖未变的数据复用，仅重建受更新影响的部分。
- **运行噪声影响归因**：配对差与运行波动难以区分；按 6.7 隔离后台负载、控制运行条件并增加独立重复，仍不可判向则保留不确定带结果。
- **局部加密未形成时间收益**：达标周期未缩短；复核计时重构和成本归因，完成预设调参预算内的执行组合比较，保留无时间收益结果。

9.4 预案与范围控制

若第一年验证未通过，先缩减几何复杂度和加密层数，采用固定加密区域，交付受限版本与验证报告；仍未通过则退回均匀基线开展执行策略比较，交付可复现性能数据与实现缺陷清单，并明确该降级尚未完成原 RQ1—RQ3，须同步修订研究范围。上述退路的前提是 MOC 求解器可访问、可修改且 GPU 资源可用；若求解器或设备条件未落实，则属资源阻断而非研究降级，须按资源条件修订目标与进度，不承诺 GPU 性能成果。

收敛变化按 5.2 处理；若正确性通过且按 6.6 确认无时间收益，则按 7.1 报告相应参数范围、成本归因及留出检验结果，回答 RQ3 中“哪些已测条件下局部加密不占优”，不以出现时间收益作为验收前提；未观测到收益方向转换时，仅报告已测无时间收益范围，不宣称已定位等时边界。

第 10 节 时间规划与阶段成果

阶段一：第一年——局部加密实现与正确性验证。暂按四年规划；学制待确认，以实际培养方案为准。先核实 MOC 求解器本体、接口与 GPU 资源条件，再实现块结构局部加密模块。交付可运行模块、可复现正确性测试集和验证报告。进入下一阶段的门槛为通过 9.2 的结构、轨迹、输运三类检查；未通过则按 9.4 第一段处理，触发降级时同步修订后续目标与门槛；资源条件未落实时，按 9.4 的资源阻断条款处理，不进入阶段二。

阶段二：第二年上半年——均匀细体素基线与公平性确认。建立基线，固定响应、组合容限、显存预算与计时口径，按 6.1 的择优标准确认基线的优化及调参程度。交付基线实现与公平性检查记录。进入下一阶段的门槛为基线在同等调参预算下达标、配置选择有记录，且计时口径与 1.3、6.4 一致。

阶段三：第二年下半年至第三年上半年——表示—执行消融与方案更新测量。按 6.3 开展两层消融，按 6.5 测量三类场景，交付配对测量数据集、分项计时与运行条件记录。进入下一阶段的门槛为 6.6 的总时间重构偏差处于正式测量前冻结的阈值内，不达标配置已单列原因。

阶段四：第三年下半年——边界刻画与留出检验。按 7.3 建立 ΔT 模型，预测仅用于边界估计与后续选点，按 7.4 开展留出检验，交付适用区间、无时间收益区间、不确定带、两条选择准则及一条不确定带处理规则，以及相应检验报告。适用区间、无时间收益区间、不确定带均允许为空；未观测到方向转换时，交付已测范围与未定位边界的说明，不要求必须发现局部加密占优区间。进入下一阶段的门槛为检验达到事前冻结的验收要求，或按 7.4 完成准则不成立及适用范围收缩报告。

阶段五：第四年——整合与写作。整合收益归因与适用边界，归档软件和实验资料，完成论文写作；交付学位论文、可复现实验集与软件说明。最终提交门槛：三个 RQ 各有对应证据与结论，选择准则及不确定带处理均有检验记录；降级情形按 9.4 修订目标验收，明示原 RQ 未完成项。

第 11 节 未来延伸：与 FW-CADIS 类减方差的衔接

11.1 快速确定论前端作为耦合基础

Wagner 等（2014）[13]所述 FW-CADIS 利用确定论正向与伴随计算构造重要性及权窗；本课题拟形成的达标方案周期可评估、表示—执行组合可选择的快速确定论能力，在原理上可作为这类流程的前端基础，但前端快不等于包含参数转换与蒙卡计算的耦合流程快。

11.2 前处理成本可控是效率前提

确定论前处理若耗时失控，可能吞噬后续蒙卡在相同统计要求下节省的计算时间，因此未来效率评价需计入前处理、数据转换和蒙卡运行的完整成本；本课题对准备时间、重建成本及峰值显存的计量，是判断前处理投入与后续节省能否形成净收益的前置能力，其效率评价前提与本课题的计量口径一致。

11.3 延伸所需条件与范围限定

未来开展衔接仍需另行落实伴随求解支持、蒙卡与确定论几何及材料映射的一致性、重要性图到权窗的转换验证，以及耦合流程的端到端计时口径；这些条件不由本课题交付，本课题不设耦合研究目标、不设耦合方法与时间节点。

参考文献

[1] Moreno C, Bader A, Wilson P. ParaStell: parametric modeling and neutronics support for stellarator fusion power plants[J]. Frontiers in Nuclear Engineering, 2024, 3: 1384788. DOI: 10.3389/fnuen.2024.1384788.

[2] Liew S L, Ku L P. Shielding Design Optimization for the Compact Ignition Tokamak Test Cell Building[J]. Fusion Technology, 1991, 20(2): 164–178. DOI: 10.13182/FST91-A29687.

[3] Tsige-Tamirat H, Fischer U, Serikov A, Stickel S. Automatic generation and validation of an ITER neutronics model from CAD data[J]. Fusion Engineering and Design, 2007, 82(15-24): 1956–1959. DOI: 10.1016/j.fusengdes.2007.06.038.

[4] Zhou F, Li S, Xue R, Bu L, Nie N, Shi P, Wang J, Hu Y, Wang Z, Wang Y, Yang Q, Yu M. Neutron particle transport 3D method of characteristic Multi GPU platform Parallel Computing[EB/OL]. arXiv:2503.17743v1, 2025-03-22（预印本）[引用日期：2026-10-20]. DOI: 10.48550/arXiv.2503.17743.

[5] Kim K M, Im J, Lee H G, Jung Y S. Verification and Performance Assessment of NuDEAL, a GPU-Accelerated Deterministic Transport Framework on Unstructured Meshes[J]. Nuclear Science and Engineering, 2026: 1–25（已在线发表，online first；2026-04-23；卷期待分配）. DOI: 10.1080/00295639.2026.2652773.

[6] Amanatides J, Woo A. A Fast Voxel Traversal Algorithm for Ray Tracing[C]. EG 1987—Technical Papers. Eurographics Association, 1987. DOI: 10.2312/egtp.19871000.

[7] Zhang W, Myers A, Gott K, Almgren A, Bell J. AMReX: Block-structured adaptive mesh refinement for multiphysics applications[J]. The International Journal of High Performance Computing Applications, 2021, 35(6): 508–526. DOI: 10.1177/10943420211022811.

[8] Gaston D R, Forget B, Smith K S, Harbour L H, Ridley G K, Giudicelli G G. Method of Characteristics for 3D, Full-Core Neutron Transport on Unstructured Mesh[J]. Nuclear Technology, 2021, 207(7): 931–953. DOI: 10.1080/00295450.2021.1871995.

[9] Boyd W, Shaner S, Li L, Forget B, Smith K. The OpenMOC method of characteristics neutral particle transport code[J]. Annals of Nuclear Energy, 2014, 68: 43–52. DOI: 10.1016/j.anucene.2013.12.012.

[10] NVIDIA Corporation. CUDA C++ Best Practices Guide[EB/OL]. Release 13.4, 2026-10-12[引用日期：2026-10-20]. https://docs.nvidia.com/cuda/pdf/CUDA_C_Best_Practices_Guide.pdf（官方页面未列 DOI）。

[11] Adinets A. CUDA Pro Tip: Optimized Filtering with Warp-Aggregated Atomics[EB/OL]. NVIDIA Technical Blog, 2014-10-01（2017 年 11 月更新）[引用日期：2026-10-20]. https://developer.nvidia.com/blog/cuda-pro-tip-optimized-filtering-warp-aggregated-atomics/（官方页面未列 DOI）。

[12] Baker C M J, Buchan A G, Pain C C, Tollit B S, Goffin M A, Merton S R, Warner P. Goal based mesh adaptivity for fixed source radiation transport calculations[J]. Annals of Nuclear Energy, 2013, 55: 169–183. DOI: 10.1016/j.anucene.2012.11.029.

[13] Wagner J C, Peplow D E, Mosher S W. FW-CADIS Method for Global and Regional Variance Reduction of Monte Carlo Radiation Transport Calculations[J]. Nuclear Science and Engineering, 2014, 176(1): 37–57. DOI: 10.13182/NSE12-33.